
一、 标注 RNA 基本二级结构单元

如下图所示:一共有 hairpin loop, internal loop, multiloop, stem, bulge 5 种基本二级结构单元(这里没有 pseudoknot, noncanonical)。



用下列字母表示基本二级结构单元。

L : paired, 5' end (R : paired, 3' end)

H : hairpin loop
T : internal loop
B : bulge loop

M : multiloop

E : external region(unpaired) RNA

parse.py 脚本中 toPairs 函数获取配对碱基对, parse 函数标注出该 RNA 序列中每个碱基所对应的基本二级结构单元, 手动将 rRNA_1.txt 分为 rRNA_1_2.txt rRNA_1_1.txt 运行命令 python parse.py 得到 seq1 和 seq2 的结果。

>seq1

>seq2

二、 SCFG 计算 RNA 二级结构

1) 构建 CYK 模型。

非终止状态: S, F, L

终止状态: A U C G (用 a 表示)

规则:

$$L->aFa$$
 $S->L$ $L->a$ $S->LS$ $F->aFa$ ' $F->LS$

2) 初始化。根据初始化条件公式:

For
$$i = 1$$
 to $n, W = S, F, L$

$$\gamma(i,i-1,W)=-\infty,$$

$$\gamma(i, i, W) = \log P(W \to x_i)$$
 if the rule $W \to x_i$ exists,

otherwise,
$$\gamma(i, i-1, W) = -\infty$$

得到本实验 CYK 模型初始化条件:

由于 1.非终止状态 L 能发射终止状态 a; 2.非终止状态 S 能发射到 L 再到终止状态 a; 因此可得:

$$\gamma(i,i,W) = \begin{cases} -\infty, & W = F \\ \log P(L \to x_i) + \log P(x_i), & W = L \\ \gamma(i,i-1,L) + \log P(S \to L) = \log P(L \to x_i) + \log P(x_i) + \log P(S \to L), & W = S \end{cases}$$

3) 动态规划迭代过程:

根据迭代公式:

For
$$i = 1$$
 to n , $i = i + 1$ to n , $W = S$, F, L

$$\gamma(i,j,W) = max \begin{cases} \gamma(i,j,Y) + logP(W \rightarrow Y) \\ \max_{i \leq k \leq j-1} \gamma(i,k,Y) + \gamma(k+1,j,Z) + log P(W \rightarrow YZ) \\ \gamma(i+1,j,Y) + logP(W \rightarrow x_iY) \\ \gamma(i,j-1,Y) + logP(W \rightarrow Yx_i) \\ \gamma(i+1,j-1,Y) + logP(W \rightarrow x_iYx_i) \end{cases}$$

根据 S, F, L 的发射规则, 无 $W \to Yx_i \pi W \to x_i Yx_i$ 整理可得:

$$\gamma(i,j,W) = \max \begin{cases} \max_{i \leq k \leq j-1} \gamma(i,k,Y) + \gamma(k+1,j,Z) + \log P(W \rightarrow YZ) & W = S, F \\ \gamma(i+1,j-1,Y) + \log P(W \rightarrow x_i Y x_i), & W = L, F \\ \gamma(i,j,Y) + \log P(W \rightarrow Y), & W = S \end{cases}$$

4) 终止条件:

$$\log P(x, \hat{\pi} \mid \theta) = \gamma(1, L, 1)$$

5) 回溯算法:

(来源AN EFFICIENT ALGORITHM FOR ALIGNING SEQUENCES TO RNA SECONDARY STRUCTURE, KAN LIU)

```
TraceBack( New Linked List l, \tau(W, i, j)=(r, k))
      If (r \text{ is } W \rightarrow a)
             Add 'T' to the end of l
             return
      If (r \text{ is } W \rightarrow Y)
             TraceBack(l, \tau(Y, i, j))
      If (r \text{ is } W \rightarrow YZ)
             TraceBack( New Linked List l_1, \tau(Y, i, k))
             TraceBack( New Linked List l_2, \tau(Z, k+1, j))
             L=Concatenation of l_1 and l_2
      If (r \text{ is } W \rightarrow aY)
             \mathsf{TraceBack}(l\ , \tau(Y, i{+}1, j))
             Add 'L' to the head of l
      If (r \text{ is } W \rightarrow Ya)
             TraceBack(l, \tau(Y, i, j-1))
             Add 'R' to the end of l
      If (r \text{ is } W \rightarrow aYb)
             TraceBack(l, \tau(Y, i+1, j-1))
             Add '>' to the head of l
             Add '<' to the end of 1
```

6) 运行 python main.py, 得到结果:

)))))))))))))))))))))))))))))))))))))))	
)))))))))))(((((((
)))))))(((((((((((((((((((((((
))))))))(((((((((((((((((((((((
((((((((((